
Uživatelský manuál Qwen Harness

Kompletní průvodce lokální chatovací a vývojovou stanicí

Verze aplikace	1.3.4
Uživatelský manuál	2026

Obsah

1. Co je Qwen Harness	3
2. Požadavky a instalace	3
3. Prohlídka desktopového rozhraní	4
4. Modely, KV cache, kontext a thinking	5
5. Odesílání, steering, Stop a průběh	6
6. Pracovní režimy	6
7. Projekty a workspace	7
8. Správa chatů	7
9. Kontext, komprese a pins	7
10. Tři vrstvy paměti	8
11. Volitelné skills	8
12. Internet a výzkum	8
13. Psaní a export dokumentů	9
14. Vývojový workflow	9
15. Ovládání počítače	10
16. Autonomie a potvrzování	10
17. Terminálové UI a CLI	11
18. Úložiště, zálohy a logy	11
19. Řešení problémů	12
20. Reference nástrojů	12
21. Praktické příklady	13
22. Provozní omezení	13

1. Co je Qwen Harness

Qwen Harness je soukromá desktopová aplikace pro Windows, která provozuje lokální jazykové modely jako obecný chat, výzkumného asistenta, partnera pro psaní, coding agenta a operátora počítače. Inference modelu běží na pracovní stanici přes llama.cpp; konverzace a projektové soubory zůstávají na lokálním disku.

Aplikace je navržena pro jednoho uživatele a jeden aktivní model. Nepoužívá paralelní modelové agenty. Aktivní model ale může paralelně spouštět nezávislé čtecí nástroje a může ponechat dlouhé příkazy běžet na pozadí.

POZNÁMKA: Inference modelu je lokální. Když model použije `web_search` nebo `web_fetch`, aplikace provádí běžné internetové požadavky na vyhledávače a veřejné webové stránky. Pokud potřebujete zcela offline relaci, vypněte `web` v `config.yaml` nebo nepoužívejte výzkumné/webové požadavky.

Hlavní schopnosti

- Běžná konverzace bez programátorského chování.
- Výzkum z více webových a dokumentových zdrojů se závěrečnou syntézou.
- Psaní a revize scénářů, článků, reportů, treatmentů a dalších dokumentů.
- Lokální vývoj projektů s nástroji pro soubory, Git, shell, testy, obrázky a rollback.
- Ovládání aplikací ve Windows podle screenshotů.
- Trvalé projekty, více chatů v projektu, třívrstvá paměť, připnuté soubory a volitelné skills.
- Anglické a české rozhraní, které lze přepnout bez ztráty aktivního chatu.

Co model vidí

Výběr projektu dá modelu přístup k danému adresáři prostřednictvím nástrojů. Neznamená to, že se obsah všech souborů vloží do kontextového okna. Model dostane kompaktní mapu projektu a jednotlivé soubory čte podle potřeby. Výjimkou jsou připnuté soubory a tři vrstvy paměti, které jsou záměrně vkládány jako trvalý kontext.

2. Požadavky a instalace

Doporučená pracovní stanice

Součást	Doporučená konfigurace
Operační systém	Windows 11, 64 bitů
GPU	NVIDIA RTX 5090 s 32 GB VRAM
Ovladač	Aktuální NVIDIA ovladač kompatibilní s přibaleným CUDA buildem
Systémová RAM	Dost pro Windows, mapování modelu, projekty a nástroje; komfortní je 64 GB a více
Volné místo	Nejméně 65 GiB pro všechny modely, runtime a pracovní data
Python	Python 3.12 při práci ze zdrojů nebo prvotním setupu
WebView	Microsoft Edge WebView2, běžně součást Windows 11

Jiné NVIDIA karty mohou fungovat, ale dodané kontexty a kvantizace byly nastaveny a ověřeny pro RTX 5090 s 32 GB. Karty s menší VRAM potřebují menší kontext, nižší kvantizaci, méně GPU vrstev nebo CPU offload.

Instalace pomocí Setup.exe

1. Spustíte `QwenHarness-Setup-<verze>.exe`.
2. Zvolte angličtinu nebo češtinu. Výchozí je angličtina.
3. Zvolte, zda chcete ikonu na ploše.
4. Při první instalaci ponechte zvolený setup prostředí a modelů po dokončení instalátoru.

5. Nechte konzolovou instalaci doběhnout. Vytvoří Python prostředí, nainstaluje závislosti, stáhne llama.cpp a nakonfigurované modely.
6. Spustíte **Qwen3.8-27B Harness** z nabídky Start nebo z plochy.

Výchozí instalační adresář je:

```
%LOCALAPPDATA%\QwenHarness
```

Kompletní download má přibližně 59 GiB a obsahuje Qwen Q4, Qwen Q5, Orinith Q5 a vision projektory. Přerušené stahování z Hugging Face lze obvykle obnovit opětovným spuštěním **Instalace prostředí a modelů** z nabídky Start.

První spuštění

Desktopový launcher kontroluje Python prostředí, závislosti, llama.cpp a potřebné soubory modelů. Chybějící části spustí instalační workflow. Po dokončení instalace se při běžném spuštění modely znovu nestahují.

Spuštění desktopové aplikace otevře nativní WebView okno, spustí Web UI a podle potřeby aktivuje llama-server s vybraným modelem. Zavření desktopové aplikace zastaví její Web UI i modelový server a uvolní grafickou paměť.

Aktualizace

Nainstalujte nový Setup.exe přes existující instalaci. Uživatelská data, modely, relace, projekty, uživatelské skills a uložený stav UI zůstanou zachovány. Soubory aplikace a distribuované systémové skills se aktualizují. Model se znovu stahuje jen tehdy, když nakonfigurovaný soubor chybí.

Odinstalace a odstranění všech dat

Odinstalace ve Windows odstraní nainstalované soubory aplikace. Velká runtime data a uživatelská data mohou zůstat, aby aktualizace nebo reinstalace nemusela vše znovu stahovat.

Chcete-li odstranit úplně vše, zkontrolujte a smažte zbývající instalační adresář pouze tehdy, když už nepotřebujete runtime\models, sessions, projects, memory, user-skills a projects.json.

VAROVÁNÍ: Smazání těchto adresářů je nevratné. Nejdříve zálohujte projekty, relace, paměť a uživatelské skills.

Spuštění ze zdrojového checkoutu

```
py -3.12 -m venv .venv
.venv\Scripts\python scripts\setup_env.py --model all
.venv\Scripts\python qwen_app.py
```

Pro terminál použijte run_cli.bat nebo .venv\Scripts\python tui.py.

3. Prohlídka desktopového rozhraní

Aplikace má rolovací levý sidebar a hlavní chatovací plochu.

Stavový panel

Horní stavový panel zobrazuje aktivní/načítaný model, stav serveru, GPU VRAM, přesnost KV cache, odhad kontextu a živý odhad generovaných tokenů. Červená znamená zastavený server nebo chybu, zelená připravený model. U kontextu se poblíž limitu objeví varování.

Pracovní režim

Dropdown **Pracovní režim** mění nástroje a chování modelu pro aktivní chat. Režim se ukládá s konkrétním chatem.

Panel SERVER

Ovladač	Výsledek
start	Načte vybraný model a otevře lokální API server.
stop	Zastaví llama-server a uvolní VRAM. Chaty zůstanou uložené.
restart	Znovu načte model, KV profil a kontext.

Změna modelu nebo KV cache automaticky vyžádá restart. Načítání obvykle trvá 10-20 sekund.

Sbalovací skupiny sidebaru

- **Kontext a předání** - ruční komprese a předání do nového chatu.
- **Změny této úlohy** - změněné soubory a rollback.
- **Rozpracovaná úloha** - obnovení práce po restartu.
- **Dlouhé operace** - procesy na pozadí a jejich ukončení.
- **Co model právě používá** - kontext a připnuté soubory.
- **Dostupné skills** - katalog a osobní složka skillů.
- **Průběh výzkumu** - zdroje, ledger a syntéza.
- **Nastavení** - model, KV, autonomie, thinking, jazyk a paměť.

Projekty a chaty

Projektový dropdown vybírá projekt nebo **žádný projekt**. Oddělené seznamy zobrazují chaty vybraného projektu a chaty bez projektu. Fulltextové hledání pokrývá všechny uložené chaty.

Zvýrazněný panel aktivního chatu obsahuje **Nový chat**, **Smazat**, přejmenování Enterem, okamžitý dropdown **Přesunout chat...** a export/import.

Chat a zadávací pole

Hlavní plocha zobrazuje úplnou viditelnou historii, i když model už pracuje jen se souhrnem starších částí. Zadávací oblast obsahuje vyšší víceřádkový prompt, **Odeslat**, **Stop**, **Příloha** a akce **Znovu**, **Vrátit**, **Větev**.

Klávesa	Výsledek
Enter	Odeslat prompt.
Ctrl+Enter	Odeslat prompt.
Shift+Enter	Vložit nový řádek.

Prompt se vyčistí okamžitě po odeslání.

4. Modely, KV cache, kontext a thinking

Model	Typické použití	Kvantizace	KV	Ověřený kontext
Qwen 3.8 27B Q5	Hlavní kvalitní model	Q5	F16/Q8	F16 96k; Q8 192k
Qwen 3.8 27B Q4	Rychlost a největší kontext	Q4	F16/Q8	F16 128k; Q8 256k
Ornith 1.5 35B-A3B Abliterated Q5	Velmi rychlý volitelný MoE	Q5	Q8	128k

Výchozí profil nové instalace je Qwen Q5/Q8/192k. Aplikace si pamatuje poslední model a KV volbu každého modelu.

Q5 používejte pro náročný vývoj, architekturu a finální kvalitu. Q4 je vhodný pro vyšší rychlost nebo kontext 256k. Ornith je extrémně rychlý, ale při reálném vývoji může být slabší než dense Qwen.

Přesnost KV

F16 dává nejvyšší přesnost attention cache, ale menší kontext. Q8 výrazně šetří VRAM a přibližně zdvojnásobuje kontext za cenu malého kompromisu. Změna KV restartuje server, nikoli chat.

Thinking

U Qwenu jsou xhigh, medium, low nativní reasoning effort a off thinking vypíná. U Ornithu je nativní pouze on/off: xhigh a medium jsou promptové vodítko, low běžné thinking chování a off vypnutí.

Reasoning tokeny používají čas a dočasný kontext; UI je živě odhaduje. Celý interní reasoning se neukládá do viditelné historie.

Produkční agent nemá limit kroků ani aplikační limit výstupních tokenů.

5. Odesílání, steering, Stop a průběh

Prompt a přílohy

Pište přirozeným jazykem a uveďte požadovaný výsledek, omezení a způsob ověření. Pomocí **Příloha** lze přidat BMP, GIF, JPEG, PNG nebo WebP: fotografie, diagramy, screenshoty, UI reference i chyby.

Steering

Další zpráva během práce modelu přesměruje aktivní úlohu: přijme se okamžitě, model dokončí nejbližší větu, hotový text zůstane uložen, upřesnění se vloží do stejné úlohy a práce pokračuje.

Stop

Stop obchází běžnou frontu a měkce ukončí generování po nejbližší větě. Proces operačního systému spuštěný na pozadí zastavte zvlášť v **Dlouhé operace**.

Živý průběh

UI rozlišuje reasoning, viditelný text, přípravu velkých tool callů, provádění nástrojů/příkazů/testů a sekundy bez tokenů. Při tvorbě velkého souboru ukazuje jméno souboru a rostoucí množství připravovaného obsahu.

6. Pracovní režimy

Režim	Použití
Diskuze	Běžný chat, analýza, učení a brainstorming bez coding procedur.
Výzkum	Web/dokumentové rešerše, persistentní ledger a závěrečná syntéza.
Psaní	Scénáře, články, reporty, textové revize a export dokumentů.
Vývoj	Repozitář, soubory, Git, shell, testy, checkpoint a rollback.
Počítač	Vývoj plus screenshot, myš, klávesnice a scrolling.

Každý chat si pamatuje vlastní režim. Režimy jsou profily schopností stejného modelu, ne samostatní agenti.

7. Projekty a workspace

Vytvoření a připojení

V **Správa projektů** vytvořte spravovaný projekt tlačítkem **Nový**, nebo pomocí **Připojit** zaregistrujte existující adresář bez kopírování.

Projekt může mít libovolný počet chatů. Každý má vlastní historii, režim, kompresi, pins, research a task state; sdílí složku a projektovou paměť.

Bez projektu a přesun chatu

Žádný projekt používá chat bez workspace; exporty jdou do relace. Dropdown **Přesunout chat...** okamžitě změní projekt, workspace, projektovou paměť a knihovnu dokumentů.

Smazání projektu

Klikněte **Smazat projekt i složku**, ověřte zobrazenou cestu a potvrďte druhým kliknutím do osmi sekund. Smaže se registrace, všechny chaty projektu, složka i veškerý obsah.

VAROVÁNÍ: Potvrzením se smaže i připojená externí složka. Nejde o odpojení. Kritické systémové cesty jsou blokovány, ale cestu vždy zkontrolujte.

8. Správa chatů

- **Nový chat** vytvoří transientní relaci, která se uloží po první zprávě.
- **Smazat** vyžaduje druhé kliknutí do šesti sekund a odstraní relaci včetně příloh, research a session exportů; projektové soubory zůstanou.
- Přejmenování se potvrzuje Enterem.
- **Znovu** zopakuje odpověď na poslední prompt.
- **Vrátit** odstraní poslední konverzační kolo, nikoli souborové změny.
- **Větev** vytvoří kopii chatu u posledního promptu včetně projektu, režimu, obrázků a pins.
- **Hledat ve všech chatech** používá SQLite fulltextový index.
- Export podporuje čitelný Markdown a strukturální JSONL; JSONL se importuje jako nový chat.
- **Předat chatu** vytvoří nový chat se souhrnem cílů, rozhodnutí, stavu a dalších kroků.

9. Kontext, komprese a pins

Panel **Co model právě používá** ukazuje odhad tokenů, viditelné/celkové zprávy, obrázky, stav komprese a pins. Ve Vývoji model dostává kompaktní repo snapshot; ostatní režimy katalog dokumentů.

Připnout soubor vloží text vybraného souboru do následujících úloh tohoto chatu. Vhodné jsou architektura, specifikace, handoff a projektová pravidla. Limit je 10 souborů a asi 40 000 znaků. Větev pins kopíruje, nový chat ne.

Při 85 % kontextu se starší část automaticky shrne. Viditelná historie se nemaže. Ruční komprese je v **Kontext a předání > Komprimovat**. Při overflow agent jednou automaticky komprimuje a request zopakuje.

10. Tři vrstvy paměti

Vrstva	Rozsah	Umístění
Globální	Všechny režimy/projekty	memory\GLOBAL.md
Režimová	Všechny chaty daného režimu	memory\MEMORY.md nebo memory\modes*.md
Projektová	Jeden workspace	<projekt>\QWEN_MEMORY.md

Paměti otevřete v **Nastavení > Paměť** nebo řekněte modelu "zapamatuj si globálně", "pro Výzkum" či "pro tento projekt". Přesun chatu přepne projektovou paměť.

11. Volitelné skills

Skills jsou pomocné SKILL.md postupy. Nespouštějí druhý model a nepřebíjejí explicitní zadání. Model vidí jen jméno a trigger popis; celé tělo načte přes read_skill podle potřeby.

Priorita je projektový .qwen-skills, potom user-skills, potom distribuované skills.

Skill	Účel
systematic-debugging	Reprodukce, trasování, hypotézy a příčina chyby.
architecture-options	Varianty architektury se zachováním zadání.
implementation-verification	Přiměřená kontrola výsledku, testů a releasu.
performance-investigation	Měřením řízená analýza výkonu.
research-synthesis	Úplná syntéza se zachováním rozporů.

Vlastní skill vytvořte přes **Dostupné skills > Otevřít složku skills** jako user-skills\nazev\SKILL.md:

```
---
name: muj-skill
description: S čím pomáhá a kdy ho má model načíst.
---

# Můj skill

Flexibilní doporučení a reference.
```

12. Internet a výzkum

Běžná práce s webem

Všechny režimy mohou používat web_search a web_fetch pro aktuální informace, veřejnou dokumentaci, chybové zprávy a webové stránky. web_fetch zpracuje HTML a umí extrahovat text z podporovaných PDF a DOCX downloadů.

Výchozí vyhledávač je Google; v config.yaml lze zvolit Google, Bing nebo automatický fallback. Fetching je read-only HTTP/HTTPS.

Výzkumný workflow

Režim Výzkum automaticky:

1. Zaznamenaná otázka.
2. Před hledáním vytvoří trvalý research plán.
3. Uloží každý dotaz a kandidátní odkaz.
4. Uloží plný čitelný obsah webových i lokálních zdrojů.

5. Sleduje coverage a ID zdrojů.
6. Zachová rozpory a menšinové informace.
7. Vytvoří závěrečnou lidsky čitelnou syntézu.

Zdroje se neskrývají ani nevyhazují podle toho, zda je model považuje za důvěryhodné. Důvěryhodnost a relevanci posuzuje uživatel. Syntéza odlišuje tvrzení zdrojů od inference a uvádí nejistoty a chybějící důkazy.

Panel výzkumu

Průběh výzkumu zobrazuje dotazy, odkazy, přečtené zdroje a stav. Umí exportovat kompletní ledger, hotovou syntézu DOCX a hotovou syntézu PDF. Export již hotové odpovědi nespouští nový výzkum.

Podporované projektové dokumenty zahrnují Markdown, text, RST, CSV, JSON, YAML, PDF a DOCX. Když Výzkum přečte lokální dokument, zaznamená jej jako zdroj.

13. Psaní a export dokumentů

Režim Psaní zachovává záměr, hlas, strukturu a omezení uživatele. Umí číst a upravovat projektové soubory bez zavádění vývojové terminologie, pokud ji uživatel nepožaduje.

Model může v každém režimu exportovat finální text přirozeným požadavkem:

```
Ulož finální odpověď jako PDF.
Vyexportuj to jako strukturovaný DOCX s názvem production-report.
Vytvoř Markdown soubor s touto syntézou.
```

Podporovány jsou Markdown, strukturovaný DOCX a PDF s Unicode/českým textem, základními tabulkami a inline formátováním.

S projektem se výstup ukládá do <projekt>\exports. Bez projektu jde do sessions\<id-chatu>\exports. Projektové exporty mohou být součástí task checkpointu a lze je podle situace rollbackovat.

14. Vývojový workflow

Poznání projektu

Na začátku úlohy dostane model aktuální repo snapshot a může použít repo_overview, procházet adresáře, hledat text a číst soubory. Snapshot je přidán na hranici úlohy, takže starší prompt cache zůstává použitelná.

Souborové operace

- read_file čte text s čísly řádků.
- search_files hledá text a podporuje glob názvu.
- write_file vytvoří nebo přepíše celý soubor.
- apply_patch provádí přesné atomické náhrady.
- view_image vloží obrázek do vision kontextu.

Checkpoint a rollback

První zápis aktivuje change journal. **Změny této úlohy** vypíší vytvořené/upravené soubory. **Vrátit změny této úlohy** obnoví journalované soubory do stavu před úlohou a odstraní soubory, které úloha vytvořila.

Chatové **Vrátit** mění konverzaci. Task rollback mění souborový systém. Jde o dvě odlišné funkce.

Git

Model umí číst status a diff a vytvořit lokální commit. git_commit staguje uvedené cesty nebo jen soubory aktuálního task journalu. Automaticky nepushuje. Commit i push požadujte výslovně.

Příkazy a testy

Krátké příkazy běží synchronně s timeoutem. Dlouhé se spouštějí na pozadí, vrátí process ID a lze je pollovat, posílat jim stdin nebo ukončit celý strom procesů.

`start_project_check` pozná testy tohoto harnessu, `pytest/pyproject`, `Node npm test/npm run check`, `Rust cargo test` a `Go go test ./...`

Finální kontrola je doporučená, ne omezení. Explicitní zadání uživatele na architekturu, formu, rozsah nebo single-file výsledek má přednost.

15. Ovládání počítače

Počítač přidává GUI nástroje ke kompletní sadě Vývoje.

Cyklus

1. Model zavolá screenshot.
2. Obrázek se podle potřeby zmenší a přiloží.
3. Model určí prvky v souřadnicích obrázku.
4. Klikne, pohne myší, scrolluje, píše nebo stiskne klávesy.
5. Dalším screenshotem ověří výsledek.

Harness přepočítá souřadnice obrázku na skutečné rozlišení primárního displeje.

GUI akce

- Screenshot a informace o obrazovce.
- Pohyb myši pro hover.
- Levé, pravé, prostřední kliknutí a dvojklik.
- Scroll na volitelné pozici.
- Přímé psaní ASCII nebo vložení Unicode/dlouhého textu přes schránku.
- Klávesy a kombinace jako Enter, Escape, Ctrl+S, Alt+F4 nebo Win+D.

Failsafe

Rychlým přesunutím fyzického kurzoru do levého horního rohu primární obrazovky aktivujete PyAutoGUI failsafe a přerušíte GUI akce.

VAROVÁNÍ: Počítač vidí obrazovku a může provádět destruktivní akce. Pro e-mail, platby, účty, mazání a citlivé workflow používejte Supervised autonomii.

16. Autonomie a potvrzování

Úroveň	Chování
Supervised	Každý zápis, shell akce a GUI akce vyžaduje potvrzení; čtení pokračuje.
Semi	První WRITE akce v úloze vyžádá potvrzení; potom úloha pokračuje.
Auto	WRITE akce pokračují bez potvrzení.

V produkci není limit agentních kroků.

Při potvrzení chat vypíše čekající akce a zobrazí **Povolit** a **Zamítnout**. Zamítnutí se vrátí modelu, aby mohl zvolit jiný postup.

Přesměrování, instalace balíčků, libovolný Python, kopírování, mazání, síťové zápisy, Git commit/push a smíšené příkazy se konzervativně považují za WRITE.

17. Terminálové UI a CLI

Instalátor přidá **Qwen3.8-27B Harness (CLI)** do nabídky Start. Spouští `run_cli.bat` a interaktivní TUI.

Příkaz	Účel
<code>/memory</code>	Zobrazit globální, režimovou a projektovou paměť.
<code>/model q4 q5 ornith_q5</code>	Přepnout model a restartovat server.
<code>/work discussion research writing development computer</code>	Zvolit pracovní režim.
<code>/mode chat agent computer</code>	Legacy kompatibilní režimová zkratka.
<code>/autonomy supervised semi auto</code>	Nastavit potvrzování.
<code>/thinking xhigh medium low off</code>	Nastavit hloubku uvažování.
<code>/ws [cesta]</code>	Zobrazit nebo nastavit workspace.
<code>/img <cesta></code>	Přiložit obrázek k dalšímu promptu.
<code>/screenshot</code>	Zachytit obrazovku.
<code>/new, /sessions, /load <id></code>	Spravovat relace.
<code>/server status start stop</code>	Ovládat inference server.
<code>/help, /exit</code>	Nápověda a ukončení.

Při potvrzení `y` povolí, `n` zamítne a `a` povolí zbývající WRITE akce v úloze. `Ctrl+C` přeruší generování.

18. Úložiště, zálohy a logy

Cesta	Obsah
<code>runtime\models</code>	GGUF modely a vision projektory
<code>runtime\llama</code>	CUDA binárky <code>llama.cpp</code>
<code>runtime\webui-state.json</code>	Model, KV, jazyk, režim, workspace a aktivní relace
<code>sessions\<id></code>	Zprávy, přílohy, task state, research, komprese a exporty
<code>projects</code>	Projekty vytvořené aplikací
<code>projects.json</code>	Registr projektů
<code>memory</code>	Globální a režimová paměť
<code><projekt>\QWEN_MEMORY.md</code>	Projektová paměť
<code>skills, user-skills, <projekt>\.qwen-skills</code>	Tři vrstvy skillů

Zálohujte projektové adresáře, `sessions`, `memory`, `user-skills` a `projects.json`. Modely lze znovu stáhnout.

Log	Použití
<code>runtime\launcher.log</code>	Launcher a start aplikace
<code>runtime\app.log</code>	Nativní aplikace a crashe
<code>runtime\webapp.log</code>	Web UI a Python chyby
<code>runtime\llama-server.log</code>	Model, kontext, CUDA, inference a timing

19. Řešení problémů

Server nespouští

Zkuste restart v panelu SERVER, ověřte model v runtime\models, přečtěte llama-server.log, zkontrolujte NVIDIA ovladač, port 8080 a volnou VRAM.

Chybí model nebo projektor

Spusťte **Instalace prostředí a modelů** z nabídky Start. Hotové soubory se přeskočí a podporovaný nedokončený download se obnoví.

Port Web UI je obsazený

Launcher najde blízký volný port nebo znovu použije existující Qwen Harness Web UI. URL je v launcher.log.

Dlouhý chat je pomalý nebo přetekl

Zkontrolujte kontext, použijte Q5/Q8 192k nebo Q4/Q8 256k, ručně komprimujte, předejte do nového chatu nebo odstraňte nepotřebné pins/obrázky. Agent při overflow jednou automaticky komprimuje a zopakuje request.

UI vypadá zamrzle

Sledujte živou aktivitu: model může přemýšlet, generovat tool call, zapisovat soubor nebo čekat na proces. Stop ukončí model; proces na pozadí ukončete v **Dlouhé operace**.

Obnovení po restartu

V **Rozpracovaná úloha** zvolte **Pokračovat v úloze**. Podle možnosti se obnoví pending potvrzení, částečný text, journal a procesní metadata.

Kde je PDF/DOCX

S projektem v <projekt>\exports, bez projektu v sessions\<id>\exports. Research panel nabídne exportovaný soubor také v UI.

Jazyk se nezměnil celý

Použijte **Nastavení > Jazyk**. UI se reloaduje se zachováním chatu. Nativní launcher může vyžadovat restart. Uložená UI volba má přednost před jazykem instalátoru.

20. Reference nástrojů

Nástroje běžně požadujete přirozeným jazykem.

Všechny režimy

Nástroj	Schopnost
read_memory, save_memory	Číst a ukládat tři vrstvy paměti.
web_search, web_fetch	Hledat a číst veřejný web/dokumenty.
context_status	Tokeny, zprávy, obrázky, pins a komprese.
pin_context_file, unpin_context_file	Spravovat pins aktuálního chatu.
list_project_documents, read_project_document	Katalog a čtení dokumentů.
list_skills, read_skill	Katalog a načtení skillů.
export_document	Export Markdown, DOCX nebo PDF.

Psaní, Vývoj a Počítač

Nástroj	Schopnost
<code>list_dir</code> , <code>read_file</code> , <code>search_files</code>	Procházet a hledat v souborech.
<code>write_file</code> , <code>apply_patch</code>	Vytvářet/přesně upravovat soubory.
<code>list_task_changes</code> , <code>undo_task_changes</code>	Task journal a rollback.
<code>view_image</code>	Vizuální analýza lokálního obrázku.

Vývoj a Počítač

Nástroj	Schopnost
<code>repo_overview</code> , <code>start_project_check</code>	Mapa repozitáře a hlavní test.
<code>git_status</code> , <code>git_diff</code> , <code>git_commit</code>	Lokální Git operace bez automatického push.
<code>run_command</code>	Krátký Bash, PowerShell nebo cmd příkaz.
<code>start_command</code> , <code>poll_command</code> , <code>send_stdin</code> , <code>terminate_command</code>	Persistentní procesy na pozadí.

Počítač

Nástroj	Schopnost
<code>screenshot</code> , <code>get_screen_info</code>	Obrazovka a souřadnice.
<code>move_mouse</code> , <code>click</code> , <code>scroll</code>	Myš a scrolling.
<code>type_text</code> , <code>press_key</code>	Text, klávesy a kombinace.

21. Praktické příklady

Diskuze: Porovnej tyto dva produkční postupy bez coding procedur.

Výzkum: Prozkoumej současný stav virtual production stages. Zachovej rozpory, uveď nejistoty a vyexportuj finální syntézu jako PDF.

Psaní: Přečti treatment v projektu, přepiš druhý akt ve stejném hlasu a ulož DOCX.

Vývoj: Projdi repozitář, reprodukuji chybu, oprav příčinu, spusť testy a shrň změny.

Paměť: Zapamatuj si pro tento projekt, že rendery patří do D:\Show\Delivery.

Připnutí: Připni docs\ARCHITECTURE.md pro tento chat.

Počítač: Udělej screenshot, změň požadované nastavení a ověř výsledek dalším screenshotem.

Export: Ulož existující odpověď jako PDF. Neprováděj nový výzkum.

22. Provozní omezení

- Jeden velký model zabere téměř celou GPU, proto je inference jednoslotová.
- Čtecí nástroje a procesy na pozadí mohou běžet souběžně.
- Přepnutí modelu/KV restartuje server a dočasnou prompt cache, nikoli historii.
- Kontextová čísla jsou odhady; tokenizace a cena obrázků závisejí na modelu.
- Model se může mýlit; ověřovací nástroje nezaručují správnost.
- Computer mode pracuje s primárním monitorem a viditelným UI.

- Web může selhat na login walls, JavaScript-only webech, CAPTCHA nebo blokových downloadech.
- Veřejné skills před instalací zkontrolujte, protože ovlivňují postup modelu.
- Git commit zůstává lokální bez výslovného požadavku na push.
- Pravidelně zálohujte nenahraditelné projekty a relace.