

---

# Uživatelský manuál Qwen Harness

Kompletní průvodce lokální chatovací a vývojovou stanicí

|                    |       |
|--------------------|-------|
| Verze aplikace     | 1.4.4 |
| Uživatelský manuál | 2026  |

# Obsah

|                                                |           |
|------------------------------------------------|-----------|
| <b>1. Co je Qwen Harness</b>                   | <b>3</b>  |
| <b>2. Požadavky a instalace</b>                | <b>3</b>  |
| <b>3. Prohlídka desktopového rozhraní</b>      | <b>4</b>  |
| <b>4. Modely, KV cache, kontext a thinking</b> | <b>6</b>  |
| <b>5. Odesílání, steering, Stop a průběh</b>   | <b>6</b>  |
| <b>6. Pracovní režimy</b>                      | <b>7</b>  |
| <b>7. Projekty a workspace</b>                 | <b>7</b>  |
| <b>8. Správa chatů</b>                         | <b>7</b>  |
| <b>9. Kontext, komprese a pins</b>             | <b>8</b>  |
| <b>10. Tři vrstvy paměti</b>                   | <b>8</b>  |
| <b>11. Volitelné skills</b>                    | <b>8</b>  |
| <b>12. Internet a výzkum</b>                   | <b>9</b>  |
| <b>13. Psaní a export dokumentů</b>            | <b>9</b>  |
| <b>14. Vývojový workflow</b>                   | <b>10</b> |
| <b>15. Ovládání počítače</b>                   | <b>11</b> |
| <b>16. Autonomie a potvrzování</b>             | <b>12</b> |
| <b>17. Terminálové UI a CLI</b>                | <b>12</b> |
| <b>18. Úložiště, zálohy a logy</b>             | <b>13</b> |
| <b>19. Řešení problémů</b>                     | <b>14</b> |
| <b>20. Reference nástrojů</b>                  | <b>15</b> |
| <b>21. Praktické příklady</b>                  | <b>16</b> |
| <b>22. Provozní omezení</b>                    | <b>17</b> |

# 1. Co je Qwen Harness

Qwen Harness je soukromá desktopová aplikace pro Windows, která provozuje lokální jazykové modely jako obecný chat, výzkumného asistenta, partnera pro psaní, coding agenta a operátora počítače. Inference modelu běží na pracovní stanici přes llama.cpp; konverzace a projektové soubory zůstávají na lokálním disku.

Aplikace je navržena pro jednoho uživatele a jeden aktivní model. Nepoužívá paralelní modelové agenty. Aktivní model ale může paralelně spouštět nezávislé čtecí nástroje a může ponechat dlouhé příkazy běžet na pozadí.

**POZNÁMKA:** Inference modelu je lokální. Když model použije `web_search` nebo `web_fetch`, aplikace provádí běžné internetové požadavky na vyhledávače a veřejné webové stránky. Pokud potřebujete zcela offline relaci, vypněte `web` v `config.yaml` nebo nepoužívejte výzkumné/webové požadavky.

## Hlavní schopnosti

- Běžná konverzace bez programátorského chování.
- Výzkum z více webových a dokumentových zdrojů se závěrečnou syntézou.
- Psaní a revize scénářů, článků, reportů, treatmentů a dalších dokumentů.
- Lokální vývoj projektů s nástroji pro soubory, Git, shell, testy, obrázky a rollback.
- Ovládání aplikací ve Windows podle screenshotů.
- Trvalé projekty, více chatů v projektu, třívrstvá paměť, připnuté soubory a volitelné skills.
- Anglické a české rozhraní, které lze přepnout bez ztráty aktivního chatu.

## Co model vidí

Výběr projektu dá modelu přístup k danému adresáři prostřednictvím nástrojů. Neznamená to, že se obsah všech souborů vloží do kontextového okna. Model dostane kompaktní mapu projektu a jednotlivé soubory čte podle potřeby. Výjimkou jsou připnuté soubory a tři vrstvy paměti, které jsou záměrně vkládány jako trvalý kontext.

# 2. Požadavky a instalace

## Doporučená pracovní stanice

| Součást         | Doporučená konfigurace                                                            |
|-----------------|-----------------------------------------------------------------------------------|
| Operační systém | Windows 11, 64 bitů                                                               |
| GPU             | NVIDIA RTX 5090 s 32 GB VRAM                                                      |
| Ovladač         | Aktuální NVIDIA ovladač kompatibilní s přibaleným CUDA buildem                    |
| Systémová RAM   | Dost pro Windows, mapování modelu, projekty a nástroje; komfortní je 64 GB a více |
| Volné místo     | Nejméně 65 GiB pro všechny modely, runtime a pracovní data                        |
| Python          | 64bitový Python 3.12 nainstalovaný samostatně; zapněte <b>Add Python to PATH</b>  |
| WebView         | Microsoft Edge WebView2, běžně součást Windows 11                                 |

Jiné NVIDIA karty mohou fungovat, ale dodané kontexty a kvantizace byly nastaveny a ověřeny pro RTX 5090 s 32 GB. Karty s menší VRAM potřebují menší kontext, nižší kvantizaci, méně GPU vrstev nebo CPU offload.

**POZNÁMKA:** Python 3.12 je povinný externí předpoklad každé instalace. Setup.exe vytvoří oddělené virtuální prostředí, ale samotný Python neobsahuje ani neinstaluje. Před instalací Qwen Harness nainstalujte 64bitovou verzi Pythonu 3.12 z [python.org](https://python.org) a zvolte **Add Python to PATH**.

## Instalace pomocí Setup.exe

1. Nainstalujte 64bitový Python 3.12 a v jeho instalátoru zapněte **Add Python to PATH**.
2. Spustěte `QwenHarness-Setup-<verze>.exe`.

3. Zvolte angličtinu nebo češtinu. Výchozí je angličtina.
4. Zvolte, zda chcete ikonu na ploše.
5. Při první instalaci ponechte zvolený setup prostředí a modelů po dokončení instalátoru.
6. Nechte konzolovou instalaci doběhnout. Vytvoří Python virtuální prostředí, nainstaluje závislosti, stáhne llama.cpp a nakonfigurované modely.
7. Spustěte **Qwen3.8-27B Harness** z nabídky Start nebo z plochy.

Výchozí instalační adresář je:

```
%LOCALAPPDATA%\QwenHarness
```

Kompletní download má přibližně 59 GiB a obsahuje Qwen Q4, Qwen Q5, Ornith Q5 a vision projekty. Přerušené stahování z Hugging Face lze obvykle obnovit opětovným spuštěním **Instalace prostředí a modelů** z nabídky Start.

## První spuštění

Desktopový launcher kontroluje Python prostředí, závislosti, llama.cpp a potřebné soubory modelů. Chybějící části spustí instalační workflow. Po dokončení instalace se při běžném spuštění modely znovu nestahují.

Spuštění desktopové aplikace otevře nativní WebView okno, spustí Web UI a podle potřeby aktivuje llama-server s vybraným modelem. Zavření desktopové aplikace zastaví její Web UI i modelový server a uvolní grafickou paměť.

## Aktualizace

Nainstalujte nový Setup.exe přes existující instalaci. Uživatelská data, modely, relace, projekty, uživatelské skills a uložený stav UI zůstanou zachováni. Soubory aplikace a distribuované systémové skills se aktualizují. Model se znovu stahuje jen tehdy, když nakonfigurovaný soubor chybí.

## Odinstalace a odstranění všech dat

Odinstalace ve Windows odstraní nainstalované soubory aplikace. Velká runtime data a uživatelská data mohou zůstat, aby aktualizace nebo reinstalace nemusela vše znovu stahovat.

Chcete-li odstranit úplně vše, zkontrolujte a smažte zbývající instalační adresář pouze tehdy, když už nepotřebujete runtime\models, sessions, projects, memory, user-skills a projects.json.

**VAROVÁNÍ:** Smazání těchto adresářů je nevratné. Nejdříve zálohujte projekty, relace, paměť a uživatelské skills.

## Spuštění ze zdrojového checkoutu

```
py -3.12 -m venv .venv
.venv\Scripts\python scripts\setup_env.py --model all
.venv\Scripts\python qwen_app.py
```

Pro terminál použijte run\_cli.bat nebo .venv\Scripts\python tui.py.

## 3. Prohlídka desktopového rozhraní

Aplikace má rolovací levý sidebar a hlavní chatovací plochu.

### Stavový panel

Horní stavový panel zobrazuje aktivní/načítaný model, stav serveru, GPU VRAM, přesnost KV cache, odhad kontextu a živý odhad generovaných tokenů. Červená znamená zastavený server nebo chybu, zelená připravený model. U kontextu se poblíž limitu objeví varování.

## Pracovní režim

Dropdown **Pracovní režim** mění nástroje a chování modelu pro aktivní chat. Režim se ukládá s konkrétním chatem.

## Panel SERVER

| Ovladač | Výsledek                                                    |
|---------|-------------------------------------------------------------|
| start   | Načte vybraný model a otevře lokální API server.            |
| stop    | Zastaví llama-server a uvolní VRAM. Chaty zůstanou uložené. |
| restart | Znovu načte model, KV profil a kontext.                     |

Změna modelu nebo KV cache automaticky vyžádá restart. Načítání obvykle trvá 10-20 sekund.

## Uspořádání sidebaru

Sidebar odpovídá běžnému pořadí práce a nezobrazuje každou funkci jako samostatný panel:

- **Pracovní prostor** drží nahoře kompaktní server, projekt, ovládání aktivního chatu a jeden sbalitelný seznam chatů.
- **Aktuální úloha** spojuje plán, změněné soubory, rollback a obnovení práce.
- **Kontext** spojuje statistiky, pins, kompresi a předání.
- **Průběh výzkumu** se objeví jen v režimu Výzkum.
- **Provoz** spojuje procesy na pozadí a izolovaný browser.
- **Nastavení a nápověda** obsahuje správu projektů, import/export chatu, model, paměť, skills a oba manuály.

Aktuální úloha, Kontext, Provoz a Nastavení sdílejí jeden povrch s jemnými oddělovači a jsou standardně sbalené.

## Projekty a chaty

Projektový dropdown vybírá projekt nebo **žádný projekt**. Oddělené seznamy zobrazují chaty vybraného projektu a chaty bez projektu. Fulltextové hledání pokrývá všechny uložené chaty.

Zvýrazněný panel aktivního chatu obsahuje **Nový chat**, **Smazat**, přejmenování Enterem, okamžitý dropdown **Přesunout chat...** a export/import.

## Chat a zadávací pole

Hlavní plocha zobrazuje úplnou viditelnou historii, i když model už pracuje jen se souhrnem starších částí. Zadávací oblast obsahuje vyšší víceřádkový prompt, **Odeslat**, **Stop**, **Příloha** a akce **Znovu**, **Vrátit**, **Větev**.

| Klávesa     | Výsledek           |
|-------------|--------------------|
| Enter       | Odeslat prompt.    |
| Ctrl+Enter  | Odeslat prompt.    |
| Shift+Enter | Vložit nový řádek. |

Prompt se vyčistí okamžitě po odeslání.

## 4. Modely, KV cache, kontext a thinking

| Model                             | Typické použití             | Kvantizace | KV     | Ověřený kontext   |
|-----------------------------------|-----------------------------|------------|--------|-------------------|
| Qwen 3.8 27B Q5                   | Hlavní kvalitní model       | Q5         | F16/Q8 | F16 96k; Q8 192k  |
| Qwen 3.8 27B Q4                   | Rychlost a největší kontext | Q4         | F16/Q8 | F16 128k; Q8 256k |
| Ornith 1.5 35B-A3B Abliterated Q5 | Velmi rychlý volitelný MoE  | Q5         | Q8     | 128k              |

Výchozí profil nové instalace je Qwen Q5/Q8/192k. Aplikace si pamatuje poslední model a KV volbu každého modelu.

Q5 používejte pro náročný vývoj, architekturu a finální kvalitu. Q4 je vhodný pro vyšší rychlost nebo kontext 256k. Ornith je extrémně rychlý, ale při reálném vývoji může být slabší než dense Qwen.

### Přesnost KV

F16 dává nejvyšší přesnost attention cache, ale menší kontext. Q8 výrazně šetří VRAM a přibližně zdvojnásobuje kontext za cenu malého kompromisu. Změna KV restartuje server, nikoli chat.

### Thinking

U Qwenu jsou xhigh, medium, low nativní reasoning effort a off thinking vypíná. U Ornithu je nativní pouze on/off: xhigh a medium jsou promptové vodítka, low běžné thinking chování a off vypnutí.

Reasoning tokeny používají čas a dočasný kontext; UI je živě odhaduje. Celý interní reasoning se neukládá do viditelné historie.

Produkční agent nemá limit kroků ani aplikační limit výstupních tokenů.

## 5. Odesílání, steering, Stop a průběh

### Prompt a přílohy

Pište přirozeným jazykem a uveďte požadovaný výsledek, omezení a způsob ověření. Pomocí **Příloha** lze přidat BMP, GIF, JPEG, PNG nebo WebP: fotografie, diagramy, screenshoty, UI reference i chyby.

### Steering

Další zpráva během práce modelu přesměruje aktivní úlohu: přijme se okamžitě, model dokončí nejbližší větu, hotový text zůstane uložen, upřesnění se vloží do stejné úlohy a práce pokračuje.

### Stop

**Stop** obchází běžnou frontu a měkce ukončí generování po nejbližší větě. Současně zruší právě čekající browser operaci nebo synchronní run\_command a ukončí jeho procesní strom. Samostatný proces spuštěný na pozadí zastavte zvlášť v **Dlouhé operace**.

### Živý průběh

UI rozlišuje reasoning, viditelný text, přípravu velkých tool callů, provádění nástrojů/příkazů/testů a sekundy bez tokenů. Při tvorbě velkého souboru ukazuje jméno souboru a rostoucí množství připravovaného obsahu.

## 6. Pracovní režimy

| Režim   | Použití                                                           |
|---------|-------------------------------------------------------------------|
| Diskuze | Běžný chat, analýza, učení a brainstorming bez coding procedur.   |
| Výzkum  | Web/dokumentové rešerše, persistentní ledger a závěrečná syntéza. |
| Psaní   | Scénáře, články, reporty, textové revize a export dokumentů.      |
| Vývoj   | Repozitář, soubory, Git, shell, testy, checkpoint a rollback.     |
| Počítač | Vývoj plus screenshot, myš, klávesnice a scrolling.               |

Každý chat si pamatuje vlastní režim. Režimy jsou profily schopností stejného modelu, ne samostatní agenti.

## 7. Projekty a workspace

### Vytvoření a připojení

V **Správa projektů** vytvořte spravovaný projekt tlačítkem **Nový**, nebo pomocí **Připojit** zaregistrujte existující adresář bez kopírování.

Projekt může mít libovolný počet chatů. Každý má vlastní historii, režim, kompresi, pins, research a task state; sdílí složku a projektovou paměť.

### Bez projektu a přesun chatu

**žádný projekt** používá chat bez workspace; exporty jdou do relace. Dropdown **Přesunout chat...** okamžitě změní projekt, workspace, projektovou paměť a knihovnu dokumentů.

### Smazání projektu

Klikněte **Smazat projekt i složku**, ověřte zobrazenou cestu a potvrďte druhým kliknutím do osmi sekund. Smaže se registrace, všechny chaty projektu, složka i veškerý obsah.

**VAROVÁNÍ:** Potvrzením se smaže i připojená externí složka. Nejde o odpojení. Kritické systémové cesty jsou blokovány, ale cestu vždy zkontrolujte.

## 8. Správa chatů

- **Nový chat** vytvoří transientní relaci, která se uloží po první zprávě.
- **Smazat** vyžaduje druhé kliknutí do šesti sekund a odstraní relaci včetně příloh, research a session exportů; projektové soubory zůstanou.
- Přejmenování se potvrzuje Enterem.
- **Znovu** zopakuje odpověď na poslední prompt.
- **Vrátit** odstraní poslední konverzační kolo, nikoli souborové změny.
- **Větev** vytvoří kopii chatu u posledního promptu včetně projektu, režimu, obrázků a pins.
- **Hledat ve všech chatech** používá SQLite fulltextový index.
- Export podporuje čitelný Markdown a strukturální JSONL; JSONL se importuje jako nový chat.
- **Předat chatu** vytvoří nový chat se souhrnem cílů, rozhodnutí, stavu a dalších kroků.

## 9. Kontext, komprese a pins

Panel **Co model právě používá** ukazuje odhad tokenů, viditelné/celkové zprávy, obrázky, stav komprese a pins. Rozpad zvlášť uvádí konverzaci/přílohy, aktuální projektový kontext a definice nástrojů. Celkový údaj proto zahrnuje i režii tool schemas.

Ve Vývoji model dostává kompaktní repo snapshot; ostatní režimy katalog dokumentů. Snapshot, pins a aktivní projektové instrukce se skládají jen pro aktuální request a neukládají se jako stále nové kopie do historie.

Harness automaticky hledá AGENTS.md, QWEN.md a CLAUDE.md od kořene projektu po adresář právě čteného nebo měněného souboru. Hlubší dokument je konkrétnější. Jde o guidance; aktuální zadání uživatele má přednost.

**Připnout soubor** vloží text vybraného souboru do následujících úloh tohoto chatu. Vhodné jsou architektura, specifikace, handoff a projektová pravidla. Limit je 10 souborů a asi 40 000 znaků. Větev pins kopíruje, nový chat ne.

Při 85 % kontextu se starší část automaticky shrne. Viditelná historie se nemaže. Ruční komprese je v **Kontext a předání > Komprimovat**. Při overflow agent jednou automaticky komprimuje a request zopakuje.

## 10. Tři vrstvy paměti

| Vrstva     | Rozsah                      | Umístění                                |
|------------|-----------------------------|-----------------------------------------|
| Globální   | Všechny režimy/projekty     | memory\GLOBAL.md                        |
| Režimová   | Všechny chaty daného režimu | memory\MEMORY.md nebo memory\modes\*.md |
| Projektová | Jeden workspace             | <projekt>\QWEN_MEMORY.md                |

Paměti otevřete v **Nastavení > Paměť** nebo řekněte modelu "zapamatuj si globálně", "pro Výzkum" či "pro tento projekt". Přesun chatu přepne projektovou paměť.

## 11. Volitelné skills

Skills jsou pomocné SKILL.md postupy. Nespouštějí druhý model a nepřebíjejí explicitní zadání. Model vidí jen jméno a trigger popis; celé tělo načte přes read\_skill podle potřeby.

Priorita je projektový .qwen-skills, potom user-skills, potom distribuované skills.

| Skill                       | Účel                                             |
|-----------------------------|--------------------------------------------------|
| systematic-debugging        | Reprodukce, trasování, hypotézy a příčina chyby. |
| architecture-options        | Varianty architektury se zachováním zadání.      |
| implementation-verification | Přiměřená kontrola výsledku, testů a releasu.    |
| performance-investigation   | Měřením řízená analýza výkonu.                   |
| research-synthesis          | Úplná syntéza se zachováním rozporů.             |

Vlastní skill vytvořte přes **Dostupné skills > Otevřít složku skills** jako user-skills\nazev\SKILL.md:

```
---
name: muj-skill
description: S čím pomáhá a kdy ho má model načíst.
---

# Můj skill

Flexibilní doporučení a reference.
```



## 12. Internet a výzkum

### Běžná práce s webem

Všechny režimy mohou používat `web_search` a `web_fetch` pro aktuální informace, veřejnou dokumentaci, chybové zprávy a webové stránky. `web_fetch` zpracuje HTML a umí extrahovat text z podporovaných PDF a DOCX downloadů.

Výchozí vyhledávač je Google; v `config.yaml` lze zvolit Google, Bing nebo automatický fallback. Fetching je read-only HTTP/HTTPS.

### Výzkumný workflow

Režim Výzkum automaticky:

1. Zaznamená otázku.
2. Před hledáním vytvoří trvalý research plán.
3. Uloží každý dotaz a kandidátní odkaz.
4. Uloží plný čitelný obsah webových i lokálních zdrojů.
5. Sleduje coverage a ID zdrojů.
6. Zachová rozpory a menšinové informace.
7. Vytvoří závěrečnou lidsky čitelnou syntézu.

Zdroje se neskrývají ani nevyhazují podle toho, zda je model považuje za důvěryhodné. Důvěryhodnost a relevanci posuzuje uživatel. Syntéza odlišuje tvrzení zdrojů od inference a uvádí nejistoty a chybějící důkazy.

### Panel výzkumu

**Průběh výzkumu** zobrazuje dotazy, odkazy, přečtené zdroje a stav. Umí exportovat kompletní ledger, hotovou syntézu DOCX a hotovou syntézu PDF. Export již hotové odpovědi nespouští nový výzkum.

Podporované projektové dokumenty zahrnují Markdown, text, RST, CSV, JSON, YAML, PDF a DOCX. Když Výzkum přečte lokální dokument, zaznamená jej jako zdroj.

## 13. Psaní a export dokumentů

Režim Psaní zachovává záměr, hlas, strukturu a omezení uživatele. Umí číst a upravovat projektové soubory bez zavádění vývojové terminologie, pokud ji uživatel nepožaduje.

Model může v každém režimu exportovat finální text přirozeným požadavkem:

```
Ulož finální odpověď jako PDF.
Vyexportuj to jako strukturovaný DOCX s názvem production-report.
Vytvoř Markdown soubor s touto syntézou.
```

Podporovány jsou Markdown, strukturovaný DOCX a PDF s Unicode/českým textem, základními tabulkami a inline formátováním.

S projektem se výstup ukládá do `<projekt>\exports`. Bez projektu jde do `sessions\<id-chatu>\exports`. Projektové exporty mohou být součástí task checkpointu a lze je podle situace rollbackovat.

## 14. Vývojový workflow

### Poznání projektu

Při každém requestu dostane model aktuální repo snapshot a platné hierarchické projektové instrukce. Může použít `repo_overview`, `project_instructions`, procházet/globovat soubory, hledat literal nebo regex, navigovat deklarace přes `find_symbol/document_symbols`, hledat použití přes `find_references` a číst relevantní rozsahy.

### Souborové operace

- `read_file` čte text s čísly řádků.
- `search_files` používá ripgrep, podporuje literal/regex, case sensitivity a glob názvu.
- `find_files` vrací soubory odpovídající globu.
- `write_file` vytvoří nebo přepíše celý soubor.
- `apply_patch` provádí přesné atomické náhrady.
- `make_directory`, `move_file`, `delete_file` jsou strukturované operace zahrnuté do rollbacku.
- `view_image` vloží obrázek do vision kontextu.

### Izolovaný browser workflow

Vývoj a Počítač obsahují persistentní headless Microsoft Edge session oddělenou od běžného browser okna uživatele:

1. `browser_open` načte lokální nebo veřejnou URL.
2. `browser_snapshot` vrátí viditelný text a interaktivní prvky s refs jako e1.
3. `browser_fill`, `browser_click`, `browser_press` pracují přes tyto refs.
4. `browser_select`, `browser_hover`, `browser_scroll` obslouží dropdowny, hover a dlouhé stránky.
5. `browser_upload` nastaví lokální file input; `browser_download` uloží download k aktivnímu chatu.
6. `browser_viewport` přepne desktop, tablet nebo mobilní rozměr.
7. Nový snapshot ověří DOM výsledek; zastaralé refs jsou odmítnuty.
8. `browser_console` a `browser_network` vracejí konzoli, HTTP responses a selhané requesty.
9. `browser_screenshot` vloží vykreslenou stránku do dalšího requestu pro Qwen vision.
10. `browser_close` nebo **Browser session > Zavřít browser** uvolní Edge proces.

Browser přežije jednotlivé agentní kroky. Režim Počítač použijte pro nativní desktopové aplikace nebo celou obrazovku Windows.

### Plán úlohy

U větší práce model vytvoří operační plán pomocí `set_task_plan` a aktualizuje kroky přes `update_task_step`. Panel **Průběh úlohy** ukazuje cíl, pending/in-progress/completed kroky, poslední validaci a kontrolu diffu. Ledger je v `task-plan.json`, přežije restart i kompresi a neobsahuje soukromý chain-of-thought.

### Checkpoint a rollback

První zápis aktivuje change journal. **Změny této úlohy** vypíší vytvořené/upravené soubory. **Vrátit změny této úlohy** obnoví journalované soubory do stavu před úlohou a odstraní soubory, které úloha vytvořila.

Chatové **Vrátit** mění konverzaci. Task rollback mění souborový systém. Jde o dvě odlišné funkce.

## Git

Model umí číst status a diff a vytvořit lokální commit. `git_commit` staguje uvedené cesty nebo jen soubory aktuálního task journalu. Automaticky nepushuje. Commit i push požadujte výslovně.

## Příkazy a testy

Krátké příkazy běží synchronně s timeoutem. Úplný stdout/stderr se ukládá do `sessions\<id-chatu>\command-logs`; model dostane začátek i konec, takže neztratí závěrečnou chybu. Stop aktivní synchronní příkaz ihned ukončí. Dlouhé příkazy na pozadí vrátí process ID a lze je pollovat, posílat jim stdin nebo ukončit celý strom procesů.

`project_validation_profile` vypíše detekované test/lint/typecheck/build příkazy. `start_project_check` spustí primární nebo pojmenovanou kontrolu. Detekce pokrývá tento harness, pytest, Node scripts, Rust, Go a .NET.

Projekt může detekci nahradit souborem `.qwen/project.yaml`:

```
checks:
- id: tests
  label: Kompletní testy
  command: npm test
  shell: powershell
  kind: test
  timeout: 900
  primary: true
```

Dokončená kontrola se zapíše do panelu. Pokud změněná úloha končí bez validace, dokončeného plánu nebo kontroly diffu, harness model jednou upozorní. Model užitečnou kontrolu provede, nebo vysvětlí, proč pro danou úlohu nemá smysl.

Finální kontrola je doporučení, ne omezení. Explicitní zadání uživatele na architekturu, formu, rozsah nebo single-file výsledek má přednost.

# 15. Ovládání počítače

Počítač přidává GUI nástroje ke kompletní sadě Vývoje.

## Cyklus

1. Model zavolá screenshot.
2. Obrázek se podle potřeby zmenší a přiloží.
3. Model určí prvky v souřadnicích obrázku.
4. Klikne, pohne myší, scrolluje, píše nebo stiskne klávesy.
5. Dalším screenshotem ověří výsledek.

Harness přepočítá souřadnice obrázku na skutečné rozlišení primárního displeje.

## GUI akce

- Screenshot a informace o obrazovce.
- Pohyb myši pro hover.
- Levé, pravé, prostřední kliknutí a dvojklik.
- Scroll na volitelné pozici.
- Přímé psaní ASCII nebo vložení Unicode/dlouhého textu přes schránku.
- Klávesy a kombinace jako Enter, Escape, Ctrl+S, Alt+F4 nebo Win+D.

## Failsafe

Rychlým přesunutím fyzického kurzoru do levého horního rohu primární obrazovky aktivujete PyAutoGUI failsafe a přerušíte GUI akce.

**VAROVÁNÍ:** Počítač vidí obrazovku a může provádět destruktivní akce. Pro e-mail, platby, účty, mazání a citlivé workflow používejte Supervised autonomii.

## 16. Autonomie a potvrzování

| Úroveň     | Chování                                                                 |
|------------|-------------------------------------------------------------------------|
| Supervised | Každý zápis, shell akce a GUI akce vyžaduje potvrzení; čtení pokračuje. |
| Semi       | První WRITE akce v úloze vyžádá potvrzení; potom úloha pokračuje.       |
| Auto       | WRITE akce pokračují bez potvrzení.                                     |

V produkci není limit agentních kroků.

Při potvrzení chat vypíše čekající akce a zobrazí **Povolit** a **Zamítnout**. Zamítnutí se vrátí modelu, aby mohl zvolit jiný postup.

Přesměrování, instalace balíčků, libovolný Python, kopírování, mazání, síťové zápisy, Git commit/push a smíšené příkazy se konzervativně považují za WRITE.

## 17. Terminálové UI a CLI

Instalátor přidá **Qwen3.8-27B Harness (CLI)** do nabídky Start. Spouští `run_cli.bat` a interaktivní TUI.

| Příkaz                                                              | Účel                                              |
|---------------------------------------------------------------------|---------------------------------------------------|
| <code>/memory</code>                                                | Zobrazit globální, režimovou a projektovou paměť. |
| <code>/model q4 q5 ornith_q5</code>                                 | Přepnout model a restartovat server.              |
| <code>/work discussion research writing development computer</code> | Zvolit pracovní režim.                            |
| <code>/mode chat agent computer</code>                              | Legacy kompatibilní režimová zkratka.             |
| <code>/autonomy supervised semi auto</code>                         | Nastavit potvrzování.                             |
| <code>/thinking xhigh medium low off</code>                         | Nastavit hloubku uvažování.                       |
| <code>/ws [cesta]</code>                                            | Zobrazit nebo nastavit workspace.                 |
| <code>/img &lt;cesta&gt;</code>                                     | Přiložit obrázek k dalšímu promptu.               |
| <code>/screenshot</code>                                            | Zachytit obrazovku.                               |
| <code>/new, /sessions, /load &lt;id&gt;</code>                      | Spravovat relace.                                 |
| <code>/server status start stop</code>                              | Ovládat inference server.                         |
| <code>/help, /exit</code>                                           | Nápověda a ukončení.                              |

Při potvrzení y povolí, n zamítne a a povolí zbývající WRITE akce v úloze. Ctrl+C přeruší generování.

## 18. Úložiště, zálohy a logy

| Cesta                                          | Obsah                                                     |
|------------------------------------------------|-----------------------------------------------------------|
| runtime\models                                 | GGUF modely a vision projektory                           |
| runtime\llama                                  | CUDA binárky llama.cpp                                    |
| runtime\webui-state.json                       | Model, KV, jazyk, režim, workspace a aktivní relace       |
| sessions\<id>                                  | Zprávy, přílohy, task state, research, komprese a exporty |
| projects                                       | Projekty vytvořené aplikací                               |
| projects.json                                  | Registr projektů                                          |
| memory                                         | Globální a režimová paměť                                 |
| <projekt>\QWEN_MEMORY.md                       | Projektová paměť                                          |
| skills, user-skills,<br><projekt>\.qwen-skills | Tři vrstvy skillů                                         |

Zálohujte projektové adresáře, sessions, memory, user-skills a projects.json.

### Kompletní offline záloha instalace

Aplikace umí vytvořit přenosnou instalační zálohu přímo ze souborů, které už jsou na tomto počítači. Otevřete **Nastavení a nápověda > Offline záloha**, zvolte **Vytvořit zálohu** a vyberte nadřazený adresář, ideálně na jiném disku. Vznikne časově označená složka QwenHarness-Offline-Backup-\*, která obsahuje:

- Všechny kompletní modely a vision projektory z runtime\models.
- Nainstalované llama.cpp a CUDA runtime z runtime\llama.
- Aktuální výběr modelů a requirements.txt.
- Kopii Python balíčků, které už jsou nainstalované v .venv.
- Odpovídající Setup.exe, pokud je dostupný v aktuálním build adresáři.
- manifest.json s velikostí a SHA-256 hashem každého zálohovaného souboru.

Modely, runtime i Python závislosti se kopírují přímo z aktuálního adresáře Qwen Harness. Při tvorbě zálohy se nic z toho znovu nestahuje. Je potřeba přibližně tolik volného místa, kolik zabírá nainstalovaný runtime; operace může trvat, protože se každý soubor kontrolně hashujete.

### Instalace z offline zálohy

1. Na cílovém počítači nainstalujte 64bitový Python 3.12 a zapněte **Add Python to PATH**. Samotný Python v záloze není.
2. Spusťte Setup.exe Qwen Harness, který je součástí zálohy. Pokud při tvorbě zálohy nebyl instalátor k dispozici, použijte odpovídající nebo novější kompatibilní Setup.exe.
3. Použijte jednu z možností:
  - Pokud je Setup.exe uvnitř zálohy vedle manifest.json, spusťte ho přímo tam; zálohu rozpozná automaticky.
  - Položte zálohu vedle Setup.exe a přejmenujte ji přesně na QwenHarness-Offline-Backup; instalátor ji rozpozná automaticky.
  - Nainstalujte Qwen Harness, v nabídce Start spusťte **Instalace z offline zálohy** a vyberte složku zálohy.
4. Běžný setup nejprve použije standardní internetové zdroje. Pokud vybraný model, llama.cpp nebo Python závislosti nelze získat online, obnoví ze zvolené lokální zálohy pouze tuto neúspěšnou součást.
5. Explicitní příkaz **Instalace z offline zálohy** v nabídce Start pořadí obrátí: nejdřív obnoví zálohu a teprve potom získá případné chybějící části.

Tlačítkem **Použit jako zálohu** zaregistrujete složku pro případ budoucího selhání downloadu, **Ověřit SHA-256** zkontroluje každý soubor podle manifestu a **Zapomenout výběr** tuto pojistku vypne. Výběr zálohy nezakazuje přístup k internetu. Setup.exe, manifest.json, README-OFFLINE.txt, requirements.txt, python-dependencies a payload musí zůstat společně v jedné záložní složce.

Offline instalační záloha neobsahuje chaty, projekty, paměť ani osobní skills. Tato nenahraditelná uživatelská data zálohujete samostatně podle seznamu výše.

| Log                      | Použití                                  |
|--------------------------|------------------------------------------|
| runtime\launcher.log     | Launcher a start aplikace                |
| runtime\app.log          | Nativní aplikace a crashe                |
| runtime\webapp.log       | Web UI a Python chyby                    |
| runtime\llama-server.log | Model, kontext, CUDA, inference a timing |

## 19. Řešení problémů

### Server nestartuje

Zkuste restart v panelu SERVER, ověřte model v runtime\models, přečtěte llama-server.log, zkontrolujte NVIDIA ovladač, port 8080 a volnou VRAM.

### Chybí model nebo projektor

Spusťte **Instalace prostředí a modelů** z nabídky Start. Hotové soubory se přeskočí a podporovaný nedokončený download se obnoví.

### Port Web UI je obsazený

Launcher najde blízký volný port nebo znovu použije existující Qwen Harness Web UI. URL je v launcher.log.

### Dlouhý chat je pomalý nebo přetekl

Zkontrolujte kontext, použijte Q5/Q8 192k nebo Q4/Q8 256k, ručně komprimujte, předejte do nového chatu nebo odstraňte nepotřebné pins/obrázky. Agent při overflow jednou automaticky komprimuje a zopakuje request.

### UI vypadá zamrzle

Sledujte živou aktivitu: model může přemýšlet, generovat tool call, zapisovat soubor nebo čekat na proces. Stop ukončí model; proces na pozadí ukončete v **Dlouhé operace**.

### Izolovaný browser nestartuje

- Microsoft Edge musí být nainstalován ve standardním umístění Windows.
- Po upgradu spusťte opravu/aktualizaci prostředí, aby se nainstaloval Python Playwright.
- Session je headless a nepoužívá běžné Edge/Chrome okno uživatele.

### Obnovení po restartu

V **Rozpracovaná úloha** zvolte **Pokračovat v úloze**. Podle možnosti se obnoví pending potvrzení, částečný text, journal a procesní metadata.

### Kde je PDF/DOCX

S projektem v <projekt>\exports, bez projektu v sessions\<id>\exports. Research panel nabídne exportovaný soubor také v UI.

## Jazyk se nezměnil celý

Použijte **Nastavení > Jazyk**. UI se reloaduje se zachováním chatu. Nativní launcher může vyžadovat restart. Uložená UI volba má přednost před jazykem instalátoru.

# 20. Reference nástrojů

Nástroje běžně požadujete přirozeným jazykem.

## Všechny režimy

| Nástroj                                       | Schopnost                                    |
|-----------------------------------------------|----------------------------------------------|
| read_memory, save_memory                      | Číst a ukládat tři vrstvy paměti.            |
| web_search, web_fetch                         | Hledat a číst veřejný web/dokumenty.         |
| context_status                                | Tokeny, zprávy, obrázky, pins a komprese.    |
| pin_context_file, unpin_context_file          | Spravovat pins aktuálního chatu.             |
| list_project_documents, read_project_document | Katalog a čtení dokumentů.                   |
| list_skills, read_skill                       | Katalog a načtení skillů.                    |
| export_document                               | Export Markdown, DOCX nebo PDF.              |
| list_dir, read_file                           | Procházet adresáře a číst rozsahy textu.     |
| search_files, find_files                      | Rychlé literal/regex hledání a glob souborů. |
| write_file, apply_patch                       | Vytvářet a atomicky upravovat text.          |
| make_directory, move_file, delete_file        | Strukturované změny s rollbackem.            |
| list_task_changes, undo_task_changes          | Task journal a rollback.                     |
| view_image                                    | Vizuální analýza lokálního obrázku.          |

## Psaní, Vývoj a Počítač

| Nástroj                         | Schopnost                         |
|---------------------------------|-----------------------------------|
| task_plan_status, set_task_plan | Číst nebo vytvořit operační plán. |
| update_task_step                | Aktualizovat stav kroků.          |
| record_task_validation          | Zapsat ručně provedenou kontrolu. |

## Vývoj a Počítač

| Nástroj                                                    | Schopnost                                        |
|------------------------------------------------------------|--------------------------------------------------|
| repo_overview, project_instructions                        | Mapa repozitáře a hierarchické instrukce.        |
| project_validation_profile, start_project_check            | Nabídka a spuštění projektových kontrol.         |
| find_symbol, document_symbols, find_references             | Deklarace, symboly dokumentu a rychlá použití.   |
| browser_open, browser_snapshot                             | Otevřít a sémanticky prohlédnout izolovaný Edge. |
| browser_fill, browser_click, browser_press, browser_wait   | Práce s refs a čekání na změny UI.               |
| browser_select, browser_hover, browser_scroll              | Dropdowny, hover a scrolling.                    |
| browser_upload, browser_download                           | Lokální upload a uložení downloadu.              |
| browser_viewport                                           | Desktopový, tabletový nebo mobilní viewport.     |
| browser_console, browser_network                           | Konzole a síťová diagnostika.                    |
| browser_screenshot, browser_close                          | Vision screenshot a zavření browseru.            |
| git_status, git_diff, git_commit                           | Lokální Git operace bez automatického push.      |
| run_command                                                | Krátký Bash, PowerShell nebo cmd příkaz.         |
| start_command, poll_command, send_stdin, terminate_command | Persistentní procesy na pozadí.                  |

## Počítač

| Nástroj                     | Schopnost                  |
|-----------------------------|----------------------------|
| screenshot, get_screen_info | Obrázovka a souřadnice.    |
| move_mouse, click, scroll   | Myš a scrolling.           |
| type_text, press_key        | Text, klávesy a kombinace. |

## 21. Praktické příklady

Diskuze: Porovnej tyto dva produkční postupy bez coding procedur.

Výzkum: Prozkoumej současný stav virtual production stages. Zachovej rozpory, uveď nejistoty a vyexportuj finální syntézu jako PDF.

Psaní: Přečti treatment v projektu, přepiš druhý akt ve stejném hlasu a ulož DOCX.

Vývoj: Projdi repozitář, reprodukuji chybu, oprav příčinu, spusť testy a shrň změny.

Paměť: Zapamatuj si pro tento projekt, že rendery patří do D:\Show\Delivery.

Připnutí: Připni docs\ARCHITECTURE.md pro tento chat.

Počítač: Udělej screenshot, změň požadované nastavení a ověř výsledek dalším screenshotem.

Export: Ulož existující odpověď jako PDF. Neprováděj nový výzkum.



## 22. Provozní omezení

### Trvalé hranice produktu

Následující funkce jsou **výslovně mimo tento produkt a nikdy nebudou přidány**, pokud vlastník osobně nezmění toto produktové rozhodnutí:

- Language servery nebo distribuční/runtime vrstva LSP. Určeným řešením je vestavěný lehký symbolový index.
- Persistentní interaktivní terminál jako hlavní workflow. Shell zůstává záložní nástroj.
- Paralelní modelová agenta, subagenti nebo multi-model orchestrace. GPU používá jeden lokální model a pracuje sekvenčně.
- Kontext s jedním milionem tokenů. Kontext zůstává v praktických profilech lokální GPU.
- Obecný plugin host, MCP ekosystém nebo široký integrační framework.

Tyto body do Qwen Harness nepatří. Nejsou odloženým roadmap backlogem.

- Jeden velký model zabere téměř celou GPU, proto je inference jednoslotová.
- Čtecí nástroje a procesy na pozadí mohou běžet souběžně.
- Přepnutí modelu/KV restartuje server a dočasnou prompt cache, nikoli historii.
- Kontextová čísla jsou odhady; tokenizace a cena obrázků závisí na modelu.
- Model se může mýlit; ověřovací nástroje nezaručují správnost.
- Computer mode pracuje s primárním monitorem a viditelným UI.
- Web může selhat na login walls, JavaScript-only webech, CAPTCHA nebo blokováných downloadech.
- Veřejné skills před instalací zkontrolujte, protože ovlivňují postup modelu.
- Git commit zůstává lokální bez výslovného požadavku na push.
- Pravidelně zálohujte nenahraditelné projekty a relace.